Trabajo Especial de la Licenciatura en Matemática Aplicada

Autor: Pedro Salomone
Director: Jorge Andrés Palombarini
Profesor Representante: Luis Ariel Biedma
Título provisorio: Integración de Aprendizaje por Refuerzo y Transformers para recomendaciones de accionables a vendedores en plataformas de e-commerce

---

Resumen

Este trabajo propone el diseño y la evaluación de un prototipo de sistema de recomendación orientado a sugerir accionables a los vendedores de Mercado Libre a través de múltiples canales de interacción (resúmenes, asistentes virtuales, notificaciones). El aporte principal reside en la integración de **Aprendizaje por Refuerzo (RL)** y arquitecturas basadas en **Transformers**, lo cual permite superar las limitaciones de los sistemas tradicionales centrados en la predicción inmediata del siguiente “ítem” a recomendar.

La idea central es modelar el proceso de recomendación como una secuencia de decisiones, en la que cada acción sugerida a un vendedor impacta en métricas de negocio acumuladas, como el aumento de ventas, la adopción de recomendaciones y la mejora del engagement. En este marco, se explorarán arquitecturas recientes como *Decision Transformer* y variantes más modernas (*Trajectory Transformer, Retentive Decision Transformer, RLT4Rec*), que plantean el entrenamiento de políticas de actuación directamente a partir de datos históricos sin necesidad de interacción en línea.

El trabajo se propone, además, evaluar la efectividad de estas técnicas frente a baselines tradicionales como GRU4Rec, SASRec y BERT4Rec, integrando datos contextuales del vendedor (categoría, reputación, estacionalidad y otras métricas específicas). Los resultados esperados incluyen la demostración de que un enfoque basado en RL (offline) puede generar políticas más robustas, generalizables y alineadas con los objetivos estratégicos de la plataforma y los vendedores en particular.

---

1. Introducción

Los sistemas de recomendación son un componente fundamental de las plataformas de e-commerce. Tradicionalmente, estos sistemas se han enfocado en el usuario final, sugiriendo productos de interés en base a su historial de navegación o compra. Sin embargo, en marketplaces como Mercado Libre, los **vendedores (sellers)** se han convertido en una audiencia clave, pues su éxito repercute directamente en la salud del ecosistema.

Recomendar “accionables” a los vendedores implica ir más allá de recomendar un producto: significa sugerir decisiones estratégicas como ajustar precios, invertir en publicidad, mejorar títulos o descripciones, o lanzar promociones específicas. A diferencia de las recomendaciones a usuarios, estas acciones tienen un **impacto acumulativo y de largo plazo**, ya que cada decisión puede modificar la trayectoria de ventas y la visibilidad del vendedor en la plataforma.

En este contexto, el **Aprendizaje por Refuerzo (RL)** surge como un paradigma natural: cada vendedor puede ser modelado como un agente, el entorno es la plataforma y sus compradores, las acciones corresponden a los accionables recomendados, y la recompensa está asociada a métricas de negocio (ventas, satisfacción, engagement). Al mismo tiempo, los **Transformers** han demostrado ser eficaces en el modelado de secuencias complejas y en la integración de información contextual. Su aplicación reciente al RL (e.g. *Decision Transformer*) habilita el **modelado de las trayectorias de interacción de los vendedores como secuencias de estados, acciones y recompensas**, ofreciendo un enfoque escalable y eficiente, que prescinde desde su concepción de la necesidad de contar con un simulador del entorno.

---

2. Motivación

2. Motivación

Los enfoques actuales en sistemas de recomendación, basados en filtrado colaborativo, modelos de secuencia (GRU4Rec, SASRec) o variantes inspiradas en NLP (BERT4Rec), son efectivos para capturar preferencias inmediatas o patrones cortos. Sin embargo, **carecen de mecanismos explícitos para optimizar a largo plazo**. Recomendar un descuento hoy puede aumentar el CTR en el corto plazo, pero quizás reduzca márgenes de ganancia en semanas siguientes; estos trade-offs solo pueden modelarse adecuadamente con RL.

Además, los vendedores interactúan con la plataforma a través de distintos canales (resúmenes, asistentes, notificaciones). Esto plantea la necesidad de un sistema flexible que pueda **adaptarse al canal y al contexto de cada recomendación**, algo difícil de lograr con técnicas tradicionales centradas en un único tipo de input.

La motivación adicional surge de avances recientes en la literatura:

- *Decision Transformer* (Chen et al., 2021) mostró que es posible entrenar políticas RL directamente como modelos de lenguaje condicionados en retornos, evitando técnicas más inestables como TD-learning.

- *Retentive Decision Transformer* (Wang et al., 2024) y *RLT4Rec* (Rajapakse & Leith, 2024) ofrecen mejoras en eficiencia, manejo de cold-start y credit assignment.

- *Transformers4Rec* (Moreira et al., 2021) probó que estas arquitecturas son efectivas en dominios de e-commerce y noticias.

Integrar estas líneas de investigación en el contexto de Mercado Libre no solo resulta novedoso, sino también altamente relevante: **un recomendador que aprende políticas basadas en resultados acumulados tiene potencial para mejorar sustancialmente la experiencia de los vendedores y el rendimiento de la plataforma.**

Motivaciones específicas en el campo académico

Más allá del impacto práctico, esta tesis se justifica también como un aporte al avance de la investigación en inteligencia artificial y sistemas de recomendación:

1. **Convergencia entre paradigmas**: el trabajo se sitúa en la intersección entre *Reinforcement Learning* y *modelos de secuencia basados en Transformers*. Ambos campos han mostrado avances extraordinarios por separado, pero su integración en escenarios de recomendación aún está en fase exploratoria.

2. **Escenario realista para RL offline**: el dominio de e-commerce ofrece un banco de pruebas natural para **Offline RL**, un área activa de investigación que enfrenta desafíos como el *distributional shift* o la sobreestimación de valores. Aplicar Decision Transformer y variantes modernas a un dataset real de vendedores permite explorar estos retos en un contexto práctico y con alto impacto.

3. **Generalización y transferencia**: se pretende analizar si políticas aprendidas en un canal (ej. asistente virtual) pueden generalizar a otros (ej. resúmenes de gestión). Esto aporta evidencia empírica sobre la capacidad de los Transformers de capturar patrones transferibles en entornos de alta heterogeneidad.

4. **Evaluación rigurosa de nuevas arquitecturas**: modelos emergentes como el *Causal Decision Transformer* o *ROLeR* son muy recientes y aún no cuentan con validaciones exhaustivas en dominios complejos. Esta tesis ofrece la posibilidad de realizar una comparación sistemática, generando conocimiento útil para la comunidad académica.

5. **Contribución metodológica**: el diseño de **funciones de recompensa específicas para recomendación de accionables** es un desafío abierto. Plantear, justificar y evaluar métricas de recompensa alineadas con objetivos de largo plazo puede aportar lineamientos metodológicos para futuros trabajos.

En resumen, este trabajo se motiva no solo por la necesidad práctica de mejorar los sistemas de recomendación de Mercado Libre, sino también por el **vacío científico en la integración de RL y Transformers en dominios de recomendación offline**, lo que ofrece una oportunidad de generar aportes originales a la literatura académica.

---

3. Objetivos

Objetivo general

Desarrollar un prototipo de sistema de recomendación basado en RL y Transformers que sugiera accionables a vendedores de Mercado Libre, optimizando métricas de negocio a largo plazo y validando su eficacia en escenarios multicanal.

Objetivos específicos

- Adaptar *Decision Transformer* y variantes recientes al dominio de e-commerce con datos históricos de interacción de sellers.
- Diseñar funciones de recompensa que reflejen objetivos estratégicos (ej. incremento de ventas, adopción de recomendaciones, mejora en exposición de productos).
- Incorporar side-information contextual (categoría, reputación, temporalidad) para enriquecer la política aprendida.
- Comparar los modelos RL + Transformers frente a baselines tradicionales (GRU4Rec, SASRec, BERT4Rec).
- Evaluar el sistema en escenarios offline y con simulaciones, analizando su robustez ante cold-start y entornos cambiantes.

---

4. Metodología

4.1 Revisión de trabajos relacionados (Estado del Arte)

Los sistemas de recomendación secuencial han evolucionado significativamente en la última década. Un punto de partida fue **GRU4Rec** (Hidasi et al., 2016), que introdujo redes recurrentes (RNNs) en la recomendación de sesiones, mostrando mejoras sobre técnicas tradicionales gracias a su capacidad de modelar dependencias temporales en secuencias de clics. Posteriormente, modelos como **SASRec** (Kang & McAuley, 2018) reemplazaron las RNNs por mecanismos de auto-atención, demostrando que los Transformers podían capturar dependencias a largo plazo de manera más estable y paralelizable. Este avance se consolidó con **BERT4Rec** (Sun et al., 2019), que aplicó el enmascarado bidireccional al estilo BERT para modelar de forma más rica las relaciones entre interacciones pasadas y futuras dentro de una sesión, logrando mejoras notables en métricas de ranking. Si bien estos modelos secuenciales marcaron hitos importantes, se centran en la predicción inmediata del próximo ítem, sin considerar explícitamente objetivos de largo plazo ni la optimización de políticas.

En paralelo, la investigación avanzó hacia frameworks más integrales como **Transformers4Rec** (Moreira et al., 2021), que adaptó arquitecturas de NLP al dominio de recomendación, facilitando el uso de side-information (categorías, metadatos, contexto de usuario) y aportando herramientas prácticas para la comunidad. Estos trabajos evidencian que los Transformers son una opción sólida para recomendaciones secuenciales, aunque siguen anclados al paradigma supervisado de predicción, en lugar de al paradigma de **optimización de retornos acumulados**.

Para abordar este aspecto, se exploró la incorporación de **Reinforcement Learning (RL)** en recomendación. **Zhao et al. (2018)** aplicaron RL a la recomendación página-a-página, mostrando que podía mejorar la diversidad y el retorno a largo plazo de las recomendaciones. De forma similar, **Zheng et al. (2018)** propusieron *Deep RL* para recomendación de noticias, en un entorno dinámico y con fuerte dependencia temporal, logrando capturar mejor los cambios de interés del usuario. Más tarde, **Chen et al. (2019)** presentaron un método de corrección off-policy en sistemas basados en REINFORCE, lo que permitió adaptar RL al entorno realista donde se dispone de grandes volúmenes de datos históricos pero no de exploración en línea libre de riesgos (vía simulación). Estos aportes fueron claves para establecer que el RL no solo es aplicable a recomendación, sino que puede integrarse de forma offline, alineándose con la naturaleza de los datos en e-commerce.

La convergencia entre RL y Transformers dio lugar a avances recientes muy relevantes. El **Decision Transformer** (Chen et al., 2021) replanteó el RL como un problema de modelado de secuencias, donde el modelo se entrena para generar acciones condicionadas al retorno esperado. Su propuesta evita técnicas inestables como TD-learning, simplificando el entrenamiento y mostrando competitividad con algoritmos RL clásicos. Luego, el **Trajectory Transformer** (Janner et al., 2021) profundizó esta línea, proponiendo discretizar y modelar trayectorias completas de estados, acciones y recompensas. En años más recientes, han surgido extensiones que buscan mejorar distintos aspectos: el **Retentive Decision Transformer** (Wang et al., 2024) optimiza la eficiencia y el manejo de memorias largas mediante enmascarado adaptativo; **RLT4Rec** (Rajapakse & Leith, 2024) adapta el paradigma específicamente a escenarios de recomendación, con énfasis en cold-start y robustez; **ROLeR** (Zhang et al., 2024) incorpora técnicas de *reward shaping* para mejorar la estimación en entornos offline; y el **Causal Decision Transformer** (Wang et al., 2023) añade consideraciones causales en el entrenamiento, buscando políticas más interpretables y resistentes a sesgos. Todos estos avances apuntan a consolidar a los Transformers como arquitectura dominante para RL offline en recomendación.

Finalmente, debe mencionarse el campo del **Offline RL**, fundamental en este proyecto por la naturaleza de los datos de Mercado Libre. La revisión de **Levine et al. (2020)** destaca los principales desafíos de este enfoque, como el *distributional shift* y la sobreestimación de valores, a la vez que plantea oportunidades para escalar RL en dominios reales sin interacción online directa. En la misma línea, **Fujimoto et al. (2019)** introdujeron *Conservative Q-Learning (CQL)*, un método robusto para RL offline que penaliza la sobreestimación de políticas fuera de distribución. Estos trabajos constituyen la base metodológica para comparar y evaluar propuestas como Decision Transformer, posicionándolo como el nuevo estándar de referencia frente a los métodos tradicionales.

En conjunto, la literatura evidencia un recorrido claro: desde los primeros intentos de modelar secuencias con RNNs, pasando por la irrupción de los Transformers en recomendación, hasta la integración de RL offline con arquitecturas de secuencia. Este plan de tesis se inscribe en esa evolución, apuntando a demostrar que la combinación de RL y Transformers en el contexto de e-commerce puede ofrecer recomendaciones más alineadas con objetivos de negocio de largo plazo y con mayor adaptabilidad a distintos canales de interacción.

4.2 Dataset

Se emplearán datos históricos de vendedores provistos por Mercado Libre:

- Interacciones con publicaciones (altas, bajas, modificaciones de precio).
- Respuestas a sugerencias previas.
- Datos contextuales: categoría, estacionalidad, reputación, métricas de engagement, entre otras. La estructura en forma de trayectorias permitirá definir estados, acciones y recompensas para entrenamiento RL offline.

4.3 Herramientas y modelos propuestos

- **Baselines**: GRU4Rec, SASRec, BERT4Rec.
- **Modelos RL**: Decision Transformer, Trajectory Transformer, Retentive DT, RLT4Rec.
- **Frameworks**: PyTorch + Transformers4Rec.
- **Funciones de recompensa**:
    - Retorno acumulado de ventas.
    - Adopción de accionables.
    - Engagement y satisfacción de vendedores.

4.4 Diseño experimental y evaluación

- Métricas de ranking: NDCG@K, Recall@K, MAP@K.
- Métricas de RL: retorno esperado acumulado, éxito por episodio.
- Evaluación offline con validación cruzada.

- Simulaciones para analizar credit assignment en escenarios de recompensas diferidas.
- Comparación de desempeño entre baselines y modelos RL-Transformer

---

5. Cronograma tentativo (diagrama de Gantt)

Semana	Actividad
1-2	Revisión bibliográfica en RL y Transformers aplicados a recomendación
3-4	Definición de hipótesis y diseño de funciones de recompensa
5-7	Recolección, limpieza y construcción de dataset de trayectorias
8-10	Implementación de baselines y primeros prototipos RL (Decision Transformer)
11-13	Evaluación experimental, análisis comparativo y ajustes
14-16	Redacción del informe final y preparación de defensa

---

6. Referencias bibliográficas preliminares

- Chen, L., Lu, K., Rajeswaran, A., Lee, K., Grover, A., Laskin, M., Abbeel, P., Srinivas, A., & Mordatch, I. (2021). Decision Transformer: Reinforcement learning via sequence modeling. *Advances in Neural Information Processing Systems, 34*, 15084–15097.
- Janner, M., Li, Q., & Levine, S. (2021). Reinforcement learning as one big sequence modeling problem. *Advances in Neural Information Processing Systems, 34*, 1273–1286.
- Wang, S., Chen, X., & Yao, L. (2024). Retentive decision transformer with adaptive masking for reinforcement learning-based recommendation systems. *arXiv preprint arXiv:2403.17634.*
- Rajapakse, D. C., & Leith, D. J. (2024). RLT4Rec: Reinforcement learning transformer for user cold start and item recommendation. *arXiv preprint arXiv:2412.07403.*

- Zhang, Y., Qiu, R., Liu, J., & Wang, S. (2024). ROLeR: Effective reward shaping in offline reinforcement learning for recommender systems. *arXiv preprint arXiv:2407.13163.*
- Wang, S., Chen, X., Jannach, D., & Yao, L. (2023). Causal decision transformer for recommender systems via offline reinforcement learning. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* (pp. 2638–2642). ACM.
- Moreira, G., Rabhi, S., Lee, J. M., Ak, R., & Oldridge, E. (2021). Transformers4Rec: Bridging the gap between NLP and sequential/session-based recommendation. In *Proceedings of the 15th ACM Conference on Recommender Systems* (pp. 143–153). ACM.
- Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2016). Session-based recommendations with recurrent neural networks. In *Proceedings of the 4th International Conference on Learning Representations (ICLR)*.
- Kang, W.-C., & McAuley, J. (2018). Self-attentive sequential recommendation. In *2018 IEEE International Conference on Data Mining (ICDM)* (pp. 197–206). IEEE.
- Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019). BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)* (pp. 1441–1450). ACM.
- Zhao, X., Zhang, Y., et al. (2018). Deep reinforcement learning for page-wise recommendations. In *Proceedings of the 12th ACM Conference on Recommender Systems (RecSys)* (pp. 95–103). ACM.
- Zheng, G., Zhang, F., Zheng, Z., Xiang, Y., Yuan, N. J., Xie, X., & Li, Z. (2018). DRN: A deep reinforcement learning framework for news recommendation. In *Proceedings of the 27th International Conference on World Wide Web (WWW)* (pp. 1673–1682). ACM.
- Chen, L., Chen, J., et al. (2019). Top-K off-policy correction for a REINFORCE recommender system. In *Proceedings of the 12th ACM International Conference on Web Search and Data Mining (WSDM)* (pp. 456–464). ACM.
- Levine, S., Kumar, A., Tucker, G., & Fu, J. (2020). Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643.*
- Fujimoto, S., Meger, D., & Precup, D. (2019). Off-policy deep reinforcement learning without exploration (conservative Q-learning). In *Proceedings of the 36th International Conference on Machine Learning (ICML)* (pp. 2052–2062). PMLR.

Palombarini, Jorge Andrés | Biedma, Luis Ariel | Salomone, Pedro